

# Untitled

Santiago Robatto, Sofía Terra

## Tarea 6: Ejercicios 6.7 6.15 7.9 y 7.10

### Exercise 6.7 (Normal-Normal grid approximation)

#### Parte A:

Como primer paso definimos la grilla de valores posibles de  $\mu$ , entre 5 y 15 by 1, dado que es el recorrido indicado en la letra.

```
[1]  5  6  7  8  9 10 11 12 13 14 15
```

Para cada valor de  $\mu$  evaluaremos el prior y la verosimilitud.

Para el prior utilizaremos el dato de letra que  $\mu \sim \mathcal{N}(10, 1.2^2)$  y evaluaremos eso.

A su vez, creamos un vector con el valor de las observaciones  $(Y_1, Y_2, Y_3, Y_4) = (7.1, 8.9, 8.4, 8.6)$  para poder hallar la verosimilitud.

	mu_grid	prior	likelihood
1	5	5.646917e-05	1.889473e-08
2	6	1.285232e-03	1.267972e-05
3	7	1.460692e-02	7.979256e-04
4	8	8.289762e-02	4.708682e-03
5	9	2.349266e-01	2.605676e-03
6	10	3.324519e-01	1.352152e-04
7	11	2.349266e-01	6.579829e-07
8	12	8.289762e-02	3.002533e-10
9	13	1.460692e-02	1.284828e-14
10	14	1.285232e-03	5.155686e-20
11	15	5.646917e-05	1.940045e-26

Finalmente ya podemos aproximar el posterior, haciendo el producto de likelihood x prior y dividiendo entre su suma. Hacer el cociente lo que hace es asegurarnos de obtener una probabilidad, dado que estamos normalizando la funcion.

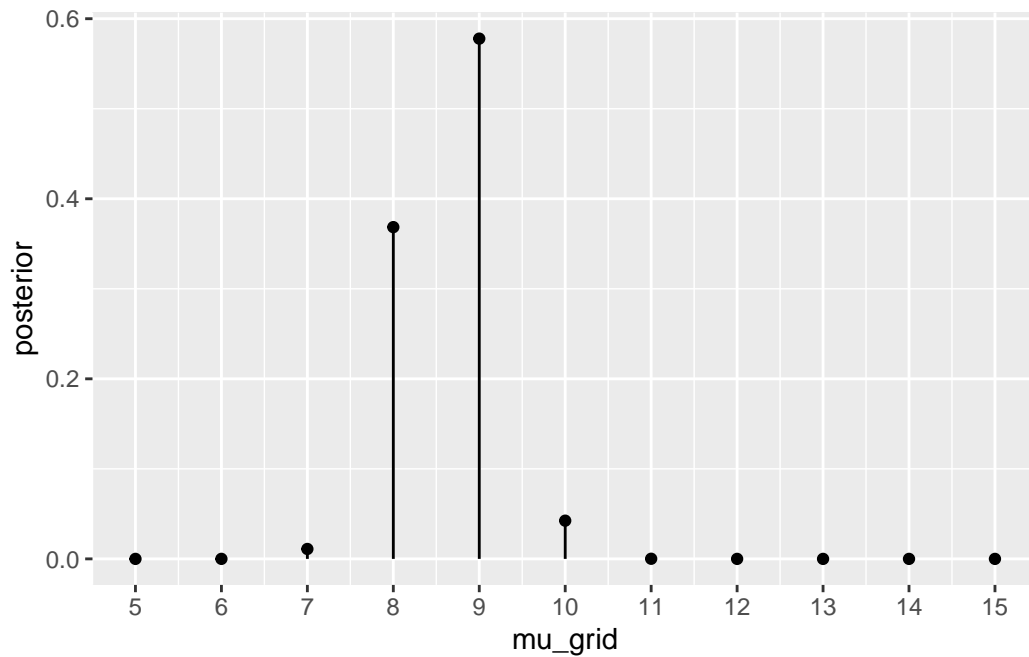
$$p(\mu_j | y) = \frac{p(y | \mu_j) p(\mu_j)}{\sum_k p(y | \mu_k) p(\mu_k)}$$

	mu_grid	prior	likelihood	unnormalized	posterior
1	5	5.646917e-05	1.889473e-08	1.066970e-12	1.007279e-09
2	6	1.285232e-03	1.267972e-05	1.629638e-08	1.538469e-05
3	7	1.460692e-02	7.979256e-04	1.165523e-05	1.100319e-02
4	8	8.289762e-02	4.708682e-03	3.903385e-04	3.685013e-01
5	9	2.349266e-01	2.605676e-03	6.121424e-04	5.778965e-01
6	10	3.324519e-01	1.352152e-04	4.495254e-05	4.243770e-02
7	11	2.349266e-01	6.579829e-07	1.545777e-07	1.459299e-04
8	12	8.289762e-02	3.002533e-10	2.489028e-11	2.349781e-08
9	13	1.460692e-02	1.284828e-14	1.876738e-16	1.771745e-13
10	14	1.285232e-03	5.155686e-20	6.626255e-23	6.255553e-20
11	15	5.646917e-05	1.940045e-26	1.095528e-30	1.034239e-27

El siguiente paso es solo un chequeo que haya funcionado bien todo. El hecho de que la suma de la variable posterior sume 1 nos asegura que esta efectivamente es una probabilidad.

	sum(unnormalized)	sum(posterior)
1	0.00105926	1

Graficamos el posterior obtenido en grid data, el cual nos devolvera los valores mas probables de  $\mu$ . De esta manera, a partir de un priori normal (continuo) y 4 observaciones, generamos una distribucion a posteriori discreta para  $\mu$ . Los valores mas probables son 8 y 9, pero al usar solo 10 valores para modelar  $\mu$  perdimos mucha precision. Es por ello que repetiremos el experimento en la parte b, pero usando 201 valores posibles para  $\mu$ .




Ademas, podemos samplear a partir de lo obtenido anteriormente y compararlo contra el posterior real:

	model	mean	mode	var	sd
1	prior	10.00000	10.00000	1.4400000	1.2000000
2	posterior	8.64698	8.64698	0.3266577	0.5715398

Por ende sabemos que el posterior teorico del ejemplo distribuye  $\mu \sim \mathcal{N}(8.64698, 0.571^2)$

Para el sampleo:

mu_grid	n	percent
7	112	0.0112
8	3687	0.3687
9	5770	0.5770
10	430	0.0430
11	1	0.0001
Total	10000	1.0000




De esta manera vemos que el histograma de aproximacion por grilla es sumamente similar al posterior real.

Sin embargo, como ya vimos antes, al haber elegido pocos valores posibles para  $\mu$  la aproximacion no es precisa.

### Parte B:

Replicaremos el codigo realizado en la parte anterior, con la unica diferencia que la secuencia para valores de  $\mu$  sera de a 0.05 en vez de a 1.

Ahora, al haber graficado para 201 casos, la aproximacion por grilla se aproxima de manera casi perfecta a la normal del posteriori que calculamos teoricamente. Al tener la variable discreta, pero ser la diferencia entre valores muy pequena, se aproxima en mayor proporcion a una normal.



Si nuevamente sampleamos, observamos que los datos practicamente la misma distribucion normal del posteriori.

