


# Ejercicios 4 y 5

Sofi Terra, Santi R

## Ejercicio 4.19

```
binary  n  percent
FAIL   10 0.7142857
PASS    4 0.2857143
Total  14 1.0000000
```

Generamos el grafico de prior, verosimilitud y posterior con plot beta binomial



Se observa que la verosimilitud es igual al posterior. Esto ocurre porque el prior es una beta (1,1) que es uniforme en el recorrido. Interpretando esto de una manera bayesiana, significa que no aporta nada de información. Se utiliza para representar neutralidad absoluta. Siempre que partimos de una beta con tales parámetros, la verosimilitud será igual al posterior.

Para el **Calculo teorico de la esperanza y modo** utilizaremos el calculo del posterior del modelo beta binomial, que sabemos que distribuye Beta ( $\alpha+y, \beta+n-y$ ).

	model	alpha	beta	mean	mode	var	sd
1	prior	1	1	0.5000	NaN	0.08333333	0.2886751
2	posterior	5	11	0.3125	0.2857143	0.01263787	0.1124183

## Parte dos: Calculo para 1990


Busqueda de la informacion para 1990 (Verosimilitud)

```
bechdel %>%
  filter(year == 1990) %>%
  tabyl(binary) %>%
  adorn_totals("row")
```

binary	n	percent
FAIL	9	0.6
PASS	6	0.4
Total	15	1.0

Partimos del posterior anterior que ya sabemos como distribuye gracias a la formula del posterior en el modelo beta binomial y cargamos la verosimilitud buscada en el paso anterior. Dicho “posterior” se convirtio en nuestro nuevo prior y se agrega una nueva verosimilitud.

```
plot_beta_binomial(alpha = 5, beta = 11, y = 6, n = 15)
```



### Calculo de la esperanza teorica

```
summarize_beta_binomial(5, 11, 6, 15)
```

	model	alpha	beta	mean	mode	var	sd
1	prior	5	11	0.3125000	0.2857143	0.012637868	0.11241827
2	posterior	11	20	0.3548387	0.3448276	0.007154006	0.08458136


### Parte 3: Ano 2000

Nuestro nuevo prior distribuirá Beta(11, 20)

```
bechdel %>%
  filter(year == 2000) %>%
  tabyl(binary) %>%
  adorn_totals("row")
```

binary	n	percent
FAIL	34	0.5396825
PASS	29	0.4603175
Total	63	1.0000000

```
plot_beta_binomial(alpha = 11, beta = 20 , y = 29, n = 63)
```



```
summarize_beta_binomial(11, 20, 29, 63)
```


	model	alpha	beta	mean	mode	var	sd
1	prior	11	20	0.3548387	0.3448276	0.007154006	0.08458136
2	posterior	40	54	0.4255319	0.4239130	0.002573205	0.05072677

#### Parte 4: Calculo de Jenna

```
bechdel %>%
  filter(year %in% c(1980, 1990, 2000)) %>%
  tabyl(binary) %>%
  adorn_totals("row")
```

binary	n	percent
FAIL	53	0.576087
PASS	39	0.423913
Total	92	1.000000

```
plot_beta_binomial(alpha = 1, beta = 1, y = 39, n = 92)
```



```
summarize_beta_binomial(1, 1, 39, 92)
```


	model	alpha	beta	mean	mode	var	sd
1	prior	1	1	0.5000000	NaN	0.083333333	0.28867513
2	posterior	40	54	0.4255319	0.423913	0.002573205	0.05072677

Se observa que Jenna llega a la misma posterior que John; probando que no importa el orden en el que mires la información, se llegará a los mismos resultados. John realiza su análisis en tres días (pasos), mientras que Jenna solo en uno. Pero al partir del mismo prior (Beta(1,1)) y utilizar las mismas muestras, llegan a los mismos posteriors.

## Ejercicio 5.7: Womens world cup

Utilizaremos `plot_gamma(1, 0.25)` dado que es el prior dado.

```
plot_gamma(1, 0.25)
```



Se observa que  $\lambda$  es decreciente y parte desde cero, con asimetría a la derecha. Es sumamente coherente con el contexto de que  $\lambda$  representa la cantidad de goles promedio, sería extraño que 20 tenga probabilidad alta, por ejemplo. Sugiere que no habrá goles en la mayoría de partidos.

## Parte 2: $Y_i$ para modelo Poisson

Se utiliza el modelo Poisson para representar a  $Y$  dado que este es útil para los conteos.  $Y$  es una variable aleatoria para representar los goles.

Cada  $Y_i$  es una observación, es decir los goles de cada partido puntual. Por otro lado  $\lambda$  representa la tasa media de ocurrencia, o sea, la cantidad promedio de goles por partido.

## Parte 3: Total de goles por partido

```
library(fivethirtyeight)
```

Some larger datasets need to be installed separately, like `senators` and `house_district_forecast`. To install these, we recommend you install the `fivethirtyeightdata` package by running:

```
install.packages('fivethirtyeightdata', repos =
```

```
'https://fivethirtyeightdata.github.io/drat/', type = 'source')
```

Adjuntando el paquete: 'fivethirtyeight'

The following object is masked \_by\_ '.GlobalEnv':

bechdel

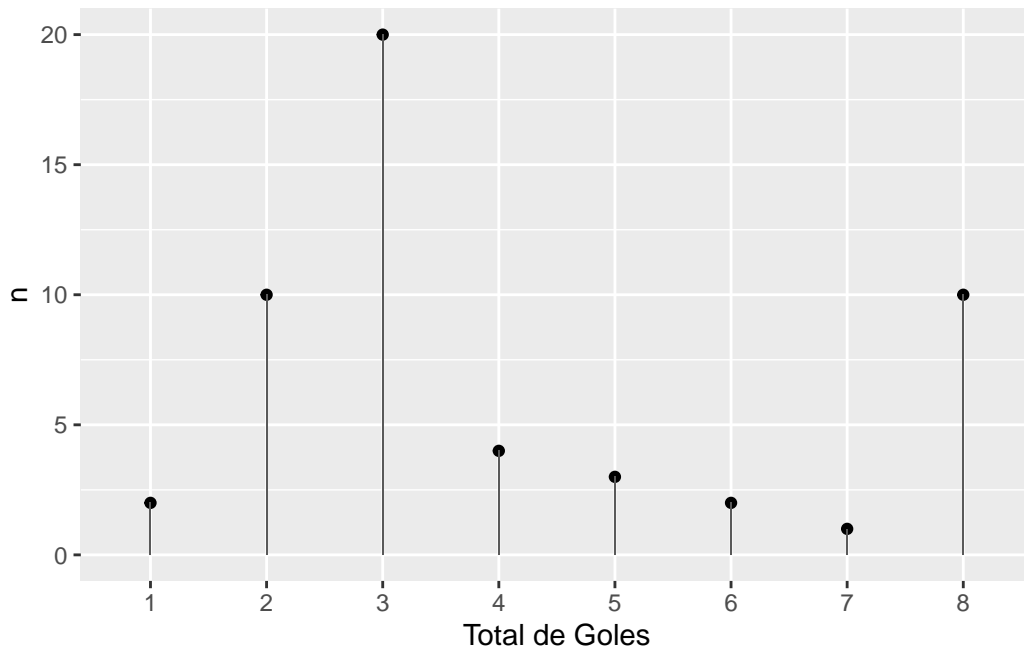
The following object is masked from 'package:bayesrules':

bechdel

```
data("wwc_2019_matches")
wwc_2019_matches <- wwc_2019_matches %>%
  mutate(total_goals = score1 + score2)

wwc_2019_matches <- wwc_2019_matches %>%
  tabyl(total_goals) %>%
  adorn_totals("row") %>%
  filter (total_goals != "Total")
```

```
ggplot(data=wwc_2019_matches, aes(x=factor(order(total_goals)), y= n)) + scale_x_discrete(nam
```



**Falta la observacion 13 pero estuvimps 1 hora para ponerla y no pudimos y tm falta el cero pero no ha habido chance!!!!**

Se observan la cantidad de goles por partido y cuantas veces se repite ese resultado, es decir la frecuencia para cada resultado.

Para poder graficar el posterior y la verosimilitud necesitaremos calcular el total de goles que se convirtieron y el total de partidos. Este ultimo se observa que es 52 en `wwc_2019_matches`.

Para calcular el total de goles, debemos multiplicar la frecuencia de cada resultado por el total de goles de ese resultado y luego sumarlo.

```
wwc_2019_matches <- wwc_2019_matches %>%
  mutate (total_goals=as.numeric(total_goals)) %>%
  mutate (golesaux = n * total_goals)
sum_goles <- sum(wwc_2019_matches$golesaux, na.rm = TRUE)
```


Removeremos el valor NA que generamos antes al utilizar `as.numeric` (generamos NA el total, que NO interesa graficarlo y alteraria la consistencia de nuestros datos)



```

wwc_2019_matches <- wwc_2019_matches %>%
  filter(!is.na(total_goals))
plot_poisson_likelihood(wwc_2019_matches$total_goals, 15)

```



Se observa que los valores mas verosimiles de  $\lambda$  rondan entre 3 y 5 goles de media por partido. Es una likelihood muy agresiva, en el sentido de que asigna probabilidad practicamente nula a 0 y 1 gol.


### Grafico del posterior

Ahora interesa calcular el posterior. Para ello utilizaremos la funcion `plot_gamma_poisson`.


```

plot_gamma_poisson(1 , 0.25, sum_goles,52) + coord_cartesian(xlim = c(0, 10))

```



En este caso, el posterior y la likelihood son practicamente iguales. Recien al hacer zoom encontramos una pequena diferencia:



Pensamos que esto ocurre por varios motivos: Tenemos un  $n$  considerablemente grande (52),

la funcion de verosimilitud esta sumamente concentrada entorno a un valor (mucha seguridad) y el prior no esta tan concentrado, sino que es mas disperso.

De esta manera, hay un cambio radical en nuestro entendimiento de la media de goles por partido. De pasar de pensar que la media podia ser 0, 1 o 2, pasamos a poder afirmar que la media de goles estara en el entorno de 3.

#### #Ejercicio 5.12: Control brains

Aclaracion: Cuando la letra del ejercicio plantea “control subjects who have not been diagnosed with a concussion”, entendemos que refiere al grupo denominado fb\_no\_concuss, pero puede haber habido un error de interpretacion.

Primero procederemos con cargar la data y filtrarla por los que no tuvieron contusiones.


```
data(football)
concussion_subjects <- football %>%
  filter(group == "fb_no_concuss")
```

```
concussion_subjects %>%
  summarize(mean(volume))
```

```
mean(volume)
1           6.4592
```


El promedio de los sujetos que no tuvieron contusiones es de 6.4592 cm<sup>3</sup> en una muestra de 25 personas.

```
ggplot(concussion_subjects, aes(x = volume)) +
  geom_density()+coord_cartesian(xlim = c(3, 9))
```



Se observa que los valores van desde 4.81 hasta 7.79 y alcanzan el maximo de densidad entorno a 6.5, que es el promedio.

```
plot_normal_likelihood(y = concussion_subjects$volume, sigma = 0.5)
```



De esta manera se visualiza la verosimilitud de  $u$ .

### Calculo del posterior

Ya tenemos todo lo necesario para identificar el posterior: El prior tiene media  $\mu = 6.5$  y  $\sigma = 0.4$ . La muestra de los que no tuvieron contusión tiene media  $\bar{y} = 6.4592$  y asumimos desvío conocido (por letra) tal que  $\sigma = 0.5$ .


Entonces el posterior se calculara de la siguiente forma, según el modelo normal-normal.

### eEl chunk de aca abajo solo lo meti para poder renderizar

```
#\$ \\\vec{y} \sim N(6.5 \cdot 0.5^2 / 25 \cdot (0.4^2 + 0.5^2) + 6.4592 \cdot (0.4^2) / 25 \cdot (0.4^2 + 0.5^2)
#Es decir: $u|\vec{y} \sim N(6.46, 0.009^2)$
```

### Parte 3: Plot del prior, verosimilitud y posterior

```
plot_normal_normal(mean = 6.5, sd = 0.4, sigma = 0.5,
                    y_bar = 6.4592, n = 25)
```



Nuevamente, dado que tenemos una verosimilitud cuyos datos estan tan concentrados, el posterior se pega mucho a este. En este caso la verosimilitud reafirma lo planteado por el prior, dado que sus medias son sumamente parecidas.

Es decir que en este caso, gracias al analisis bayesiano, reforzamos nuestro pensamiento inicial sobre donde se situa la media y ganamos precision.

```
summarize_normal_normal(mean = 6.5, sd = 0.4, sigma = 0.5,
                        y_bar = 6.4592, n = 25)
```

	model	mean	mode	var	sd
1	prior	6.5000	6.5000	0.1600000000	0.40000000
2	posterior	6.4616	6.4616	0.009411765	0.09701425

De esta manera confirmamos que nuestro posterior calculado manualmente en la Parte 2 era correcto.